

课后练习4

1 问题一

1.1

设四个属性分别为 O, T, H, W ，则我们可以分别计算它们对应的information gain.

$$H(D) = -(\frac{9}{14} \log \frac{9}{14} + \frac{5}{14} \log \frac{5}{14}) \approx 0.94029$$

$$g(D, O) = H(D) - H(D|O)$$

$$\begin{aligned} &= H(D) - (\frac{5}{14}[-(\frac{3}{5} \log \frac{3}{5} + \frac{2}{5} \log \frac{2}{5})] + \frac{4}{14}[-(\frac{4}{4} \log \frac{4}{4})] + \frac{5}{14}[-(\frac{3}{5} \log \frac{3}{5} + \frac{2}{5} \log \frac{2}{5})]) \\ &= 0.24675 \end{aligned}$$

$$g(D, T) = H(D) - H(D|T)$$

$$\begin{aligned} &= H(D) - (\frac{4}{14}[-(\frac{2}{4} \log \frac{2}{4} + \frac{2}{4} \log \frac{2}{4})] + \frac{6}{14}[-(\frac{4}{6} \log \frac{4}{6} + \frac{2}{6} \log \frac{2}{6})] + \frac{4}{14}[-(\frac{1}{4} \log \frac{1}{4} + \frac{3}{4} \log \frac{3}{4})]) \\ &= 0.029227 \end{aligned}$$

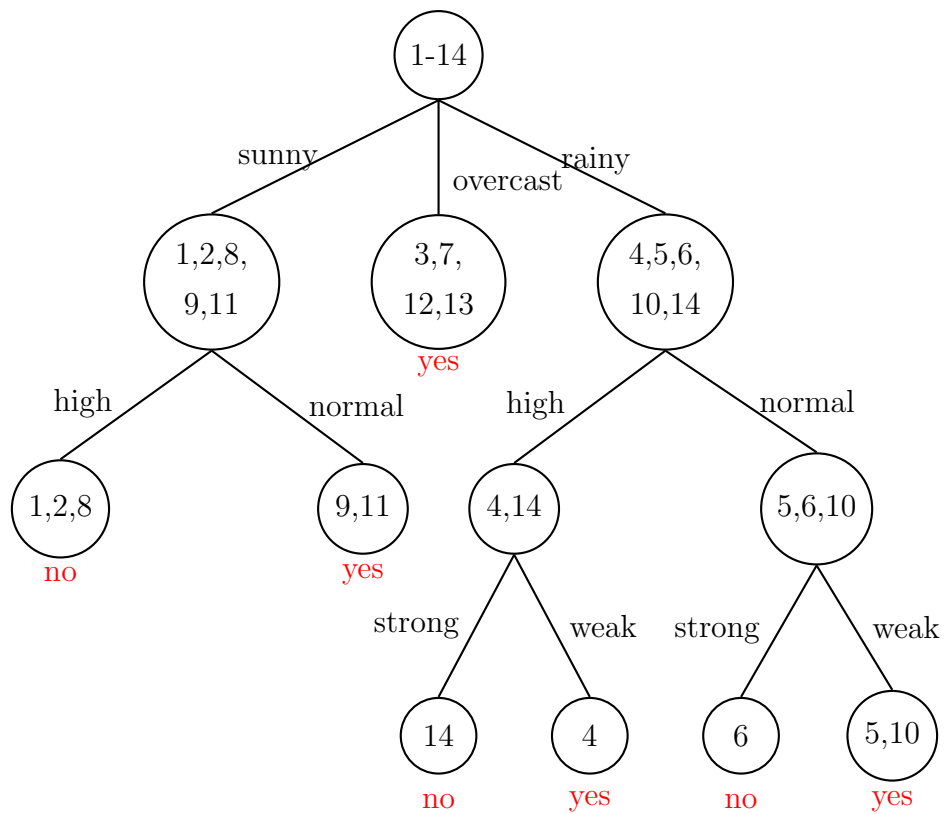
$$g(D, H) = H(D) - H(D|H)$$

$$\begin{aligned} &= H(D) - (\frac{7}{14}[-(\frac{3}{7} \log \frac{3}{7} + \frac{4}{7} \log \frac{4}{7})] + \frac{7}{14}[-(\frac{1}{7} \log \frac{1}{7} + \frac{6}{7} \log \frac{6}{7})]) \\ &= 0.15184 \end{aligned}$$

$$g(D, W) = H(D) - H(D|W)$$

$$\begin{aligned} &= H(D) - (\frac{8}{14}[-(\frac{2}{8} \log \frac{2}{8} + \frac{6}{8} \log \frac{6}{8})] + \frac{6}{14}[-(\frac{3}{6} \log \frac{3}{6} + \frac{3}{6} \log \frac{3}{6})]) \\ &= 0.04813 \end{aligned}$$

根据计算得到的information gain，我们可以相应建树：



1.2

根据得到的树模型可知，此时到达了{9,11}节点，应该进行户外活动

2 问题二

2.1

使用Bootstrapping方法，从 N 个样本中每次选一个，有放回地选择 $N' = pN$ 次，那么一个样本未被选中的概率即为

$$\begin{aligned} P &= \left(1 - \frac{1}{N}\right)^{N'} \\ &= \left(1 - \frac{1}{N}\right)^{pN} \end{aligned}$$

当 N 趋于无穷时，

$$\begin{aligned} &\lim_{N \rightarrow \infty} \left(1 - \frac{1}{N}\right)^{pN} \\ &= \left(\lim_{N \rightarrow \infty} \left(1 - \frac{1}{N}\right)^N\right)^p \\ &= \left(\frac{1}{e}\right)^p \\ &= e^{-p} \end{aligned}$$

因此总共有 $N \cdot e^{(-p)}$ 个样本不会被采样到

2.2

一个样本被分类错误，当且仅当有至少两个决策树的分类是错误的。因此被错误分类的总概率为

$$\begin{aligned} E(G) &= E(g_1)E(g_2)E(g_3) + E(g_1)E(g_2)(1 - E(g_3)) + E(g_1)(1 - E(g_2))E(g_3) + (1 - E(g_1))E(g_2)E(g_3) \\ &= 0.15 \times 0.25 \times 0.3 + 0.15 \times 0.25 \times 0.7 + 0.15 \times 0.75 \times 0.3 + 0.85 \times 0.25 \times 0.3 \\ &= 0.135 \end{aligned}$$

3 问题三

3.1

已知平方损失函数为

$$L(h) = \sum_{(x_i, y_i) \in D} (y_i - g^{(T)}(x_i))^2$$

设第 t 步得到的 $g^{(t)}(x_i)$ 与 y_i 的残差为 $r_i^{(t)}$:

$$r_i^{(t)} = y_i - g^{(t)}(x_i)$$


求偏导得到

$$\begin{aligned} \frac{\partial L}{\partial \alpha_t} &= \sum_{(x_i, y_i) \in D} 2(y_i - g^{(T-1)}(x_i) - \alpha_t f_t(x_i))(-f_t(x_i)) = 0 \\ &\Leftrightarrow \sum_{(x_i, y_i) \in D} (y_i - g^{(T-1)}(x_i) - \alpha_t f_t(x_i))f_t(x_i) = 0 \\ &\Leftrightarrow \sum_{(x_i, y_i) \in D} f_t(x_i)(y_i - g^{(T-1)}(x_i)) = \alpha_t \sum_{(x_i, y_i) \in D} f_t^2(x_i) \quad (f_t^2(x_i) = 1) \\ &\Leftrightarrow \alpha_t = \frac{\sum_{(x_i, y_i) \in D} f_t(x_i)r_i^{T-1}}{|D|} \end{aligned}$$

3.2

T 最小为 2，如图所示，对于 f_1 ，有两个点被分错，于是

$$\begin{aligned} e_1 &= 0.4 \\ \alpha_1 &= \frac{1}{2} \log(1.5) = 0.2027 \end{aligned}$$



可以更新参数得到

$$\bar{w}_1^{(2)} = \bar{w}_2^{(2)} = 0.2449$$

$$\bar{w}_3^{(2)} = \bar{w}_4^{(2)} = \bar{w}_5^{(2)} = 0.1633$$

$$w_1^{(2)} = w_2^{(2)} = 0.245$$

$$w_3^{(2)} = w_4^{(2)} = w_5^{(2)} = 0.167$$

对于 f_2 ，同样有两个点被分错

$$e_2 = 0.334$$

$$\alpha_2 = \frac{1}{2} \log(0.666/0.334) = 0.151$$

可以发现此时 f_1 和 f_2 就可以将数据集正确分类，因此 $T_{min} = 2$

3.3

可以从以下几个角度来缓解Adaboost过拟合:

1. 增大数据集
2. 降低弱分类器 f_t 的复杂度
3. 增加正则化项，使用L1或L2正则化

4 问题四

4.1

4.2

4.3