

# 课后练习5

## 1 问题一

### 1.1

我们已知

$$X = \begin{pmatrix} 3 & 4 \\ 5 & 6 \\ 1 & 2 \\ 4 & 3 \\ 2 & 5 \end{pmatrix} \quad \bar{x} = \begin{pmatrix} 3 & 4 \end{pmatrix}$$

因此

$$\hat{X} = \begin{pmatrix} 0 & 0 \\ 2 & 2 \\ -2 & -2 \\ 1 & -1 \\ -1 & 1 \end{pmatrix}$$
$$\Sigma = \frac{1}{n} \hat{X}^T \hat{X} = \begin{pmatrix} 2 & 1.2 \\ 1.2 & 2 \end{pmatrix}$$

对 $\Sigma$ 进行特征值分解得到

$$\Sigma = W^T \Lambda W \approx \begin{pmatrix} -0.707 & 0.707 \\ 0.707 & 0.707 \end{pmatrix} \begin{pmatrix} 0.8 & 0 \\ 0 & 3.2 \end{pmatrix} \begin{pmatrix} -0.707 & 0.707 \\ 0.707 & 0.707 \end{pmatrix}$$

投影矩阵 $W$ 及投影后的数据为

$$W = \begin{pmatrix} -0.707 & 0.707 \\ 0.707 & 0.707 \end{pmatrix}$$
$$X' = XW = \begin{pmatrix} 0.707 & 4.949 \\ 0.707 & 7.777 \\ 0.707 & 2.121 \\ -0.707 & 4.949 \\ -2.121 & 4.949 \end{pmatrix}$$




图 1: 1.1

## 1.2

保证不同维度正交，可以消除不同维度之间的相互影响，使得不同维度之间相互独立，互不影响

## 2 问题二

### 2.1

1.  $\mu_1 = (1, 1)$   $\mu_2 = (6, 7)$
2.  $(1, 1)(1, 2)(2, 1)(3, 4)$ 被分配到 $\mu_1$ ， $(6, 7)(7, 6)$ 被分配到 $\mu_2$
3.  $\mu_1 = (1.75, 2)$   $\mu_2 = (6.5, 6.5)$
4.  $(1, 1)(1, 2)(2, 1)(3, 4)$ 被分配到 $\mu_1$ ， $(6, 7)(7, 6)$ 被分配到 $\mu_2$
5. 收敛

### 2.2

1.  $\mu_1 = (1, 2)$   $\mu_2 = (3, 4)$
2.  $(1, 1)(1, 2)(2, 1)$ 被分配到 $\mu_1$ ， $(3, 4)(6, 7)(7, 6)$ 被分配到 $\mu_2$
3.  $\mu_1 = (1.33, 1.33)$   $\mu_2 = (5.33, 5.67)$

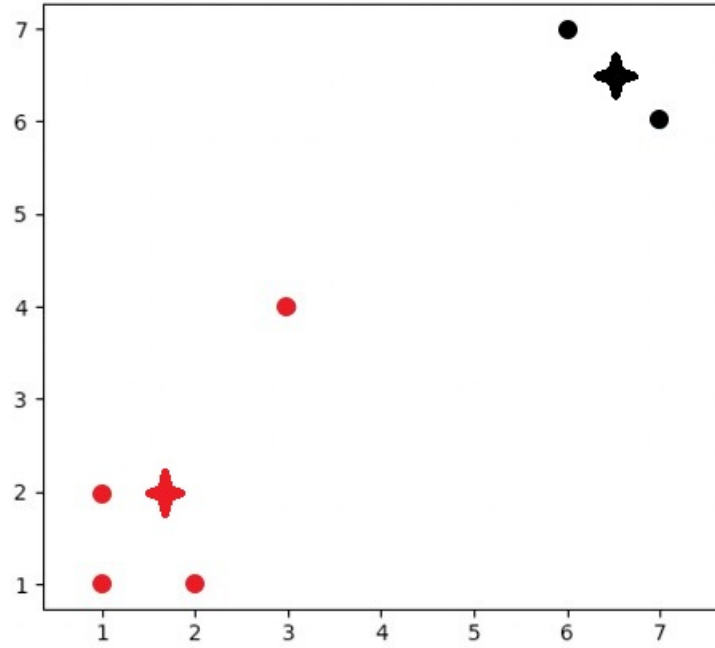


图 2: 2.1

4. (1, 1)(1, 2)(2, 1)被分配到 $\mu_1$ , (3, 4)(6, 7)(7, 6)被分配到 $\mu_2$
5. 收敛

## 2.3

初始中心点的选择会影响算法的收敛过程, 使得算法陷入局部最优解而不是全局最优解, 导致聚类结果的不同。图1的结果更优, 因为(3, 4)确实要离(1, 1)(1, 2)(2, 1)这一簇更近一些

## 3 问题三

我们已知高斯混合模型中对软标签的更新过程为

$$\gamma_{ik} = \frac{\pi_k N(x_i | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j N(x_i | \mu_j, \Sigma_j)}$$

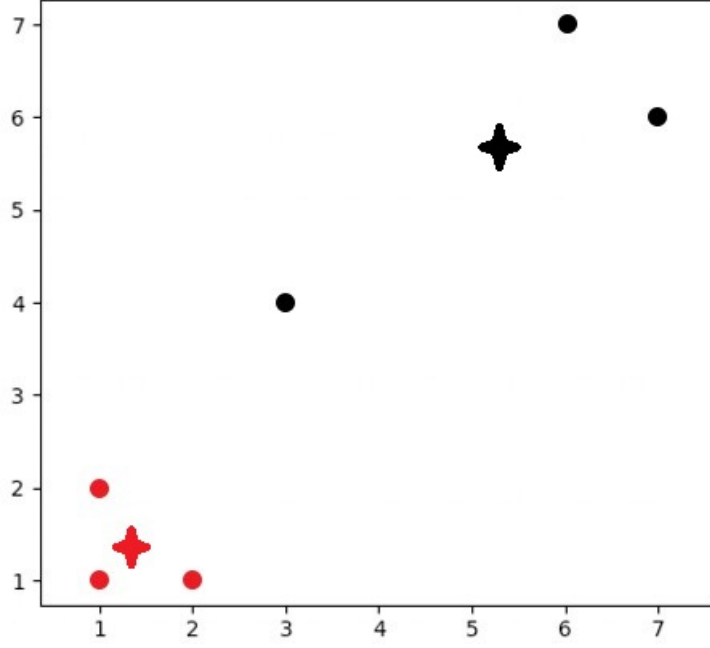


图 3: 2.2

现在 $\Sigma = \epsilon I$ ，展开正态分布

$$\begin{aligned}
 \gamma_{ik} &= \frac{\pi_k \frac{1}{(2\pi^{n/2}|\Sigma|^{1/2})} \exp(-\frac{1}{2}(x_i - \mu_k)^T \Sigma^{-1}(x_i - \mu_k))}{\sum_{j=1}^K \pi_j \frac{1}{(2\pi^{n/2}|\Sigma|^{1/2})} \exp(-\frac{1}{2}(x_i - \mu_j)^T \Sigma^{-1}(x_i - \mu_j))} \\
 &= \frac{\pi_k \exp(-\frac{1}{2\epsilon}(x_i - \mu_k)^T (x_i - \mu_k))}{\sum_{j=1}^K \pi_j \exp(-\frac{1}{2\epsilon}(x_i - \mu_j)^T (x_i - \mu_j))} \\
 &= \frac{\pi_k \exp(-\frac{1}{2\epsilon}\|x_i - \mu_k\|^2)}{\sum_{j=1}^K \pi_j \exp(-\frac{1}{2\epsilon}\|x_i - \mu_j\|^2)}
 \end{aligned}$$

当 $\epsilon \rightarrow 0$ 时，对于数据 $x_i$ ，假设其属于第 $k$ 类的概率最大，那么该数据点与 $\mu_k$ 的距离会非常近即有 $\|x_i - \mu_k\|^2 \rightarrow 0$ ，于是 $\exp(-\frac{\|x_i - \mu_k\|^2}{2\epsilon}) \rightarrow 1$ ，对任意 $j \neq k$ ， $\exp(-\frac{\|x_i - \mu_j\|^2}{2\epsilon}) \rightarrow 0$ ，因此

$$\gamma_{ik} = \begin{cases} 1 & \text{if } k = \underset{j=1, \dots, K}{\operatorname{argmin}} \|x_i - \mu_j\|^2 \\ 0 & \text{otherwise} \end{cases}$$

现在这与K-means的硬标签完全相同，可以证明当 $\epsilon \rightarrow 0$ 时，高斯混合模型与K-means等价

## 4 问题四

### 4.1

$$\begin{aligned}
 \gamma_k^{(i)} &= P(z_k^{(i)} = 1 | x^{(i)}, \pi, \mathbf{p}) \\
 &= \frac{P(x^{(i)} | z_k^i = 1) P(z_k^{(i)} = 1)}{\sum_{j=1}^K P(x^{(i)} | z_j^i = 1) P(z_j^{(i)} = 1)} \\
 &= \frac{\pi_k P(x^{(i)} | p^{(k)})}{\sum_{j=1}^K \pi_j P(x^{(i)} | p^{(j)})}
 \end{aligned}$$

### 4.2

优化目标为

$$\max_{\mathbf{p}, \pi} \sum_{i=1}^N \sum_{k=1}^K \gamma_k^{(i)} (\log \pi_k + \log P(x^{(i)} | p^{(k)})) \quad \text{s.t.} \quad \sum_{k=1}^K \pi_k = 1$$

构造拉格朗日方程

$$L(\mathbf{p}, \pi, \lambda) = \sum_{i=1}^N \sum_{k=1}^K \gamma_k^{(i)} (\log \pi_k + \log P(x^{(i)} | p^{(k)})) + \lambda (1 - \sum_{k=1}^K \pi_k)$$

计算  $\pi_k$

$$\begin{aligned}
 \frac{\partial L}{\partial \pi_k} &= \sum_{i=1}^N \frac{\gamma_k^{(i)}}{\pi_k} - \lambda = 0 \\
 \pi_k &= \frac{\sum_{i=1}^N \gamma_k^{(i)}}{\lambda}
 \end{aligned}$$

由于已知

$$\begin{aligned}
 \lambda \sum_{k=1}^K \pi_k &= \sum_{i=1}^N \sum_{k=1}^K \gamma_{ik} = N \\
 \Rightarrow \lambda &= N
 \end{aligned}$$

因此

$$\pi_k = \frac{\sum_{i=1}^N \gamma_k^{(i)}}{N}$$

计算 $p^{(k)}$ 的第 $d$ 个分量 $p_d^{(k)}$

$$\begin{aligned}
\frac{\partial L}{\partial p_d^{(k)}} &= \sum_{i=1}^N \gamma_k^{(i)} \frac{\partial \log P(x_d^{(i)} | p_d^{(k)})}{\partial p_d^{(k)}} \\
&= \sum_{i=1}^N \gamma_k^{(i)} \frac{\partial \log ((p_d^{(k)})^{x_d^{(i)}} (1 - p_d^{(k)})^{1-x_d^{(i)}})}{\partial p_d^{(k)}} \\
&= \sum_{i=1}^N \gamma_k^{(i)} \left( \frac{x_d^{(i)}}{p_d^{(k)}} - \frac{1 - x_d^{(i)}}{1 - p_d^{(k)}} \right) \\
&= \sum_{i=1}^N \gamma_k^{(i)} (x_d^{(i)} - p_d^{(k)}) = 0 \\
p_d^{(k)} &= \frac{\sum_{i=1}^n \gamma_k^{(i)} x_d^{(i)}}{\sum_{i=1}^n \gamma_k^{(i)}}
\end{aligned}$$

因此 $p^{(k)}$ 为

$$p^{(k)} = \frac{\sum_{i=1}^n \gamma_k^{(i)} x^{(i)}}{\sum_{i=1}^n \gamma_k^{(i)}}$$